

杨易为

✉ victoryang00@ucsc.edu · 🌐 asplos.dev 🐙 vickiepgt

教育经历

加州大学圣克鲁兹分校, 在读 Ph.D. 2022/09 – 2028/06

- 计算机科学, 导师为Andi Quinn, 2022 秋体系结构助教

上海科技大学, 本科 2018/09 – 2022/06

- 计算机科学, 完成编译原理, 操作系统, 网络, 数据库, 并行计算, 凸优化, 强化学习等课程, 2021&22 春编译原理助教

工作经历

Zettai 有限责任公司 2025/09 – 现在

(创始人) 创始人

- 创立 zettai 有限责任公司, 专注于编译器驱动的异构 XPU 执行。

Oxmiq 实验室 2025/06 – 2025/09

(编译器工程师) 编译器实习生

- 将 HetGPU 应用于生产环境。

跃申有限公司 2020/07 – 2020/09

(Linux 组) HPC 自动化运维实习

- 应用线性回归法进行高频交易盘账模拟。
- 在 Linux 中自动调度作业集成分配 cpu 核心绑定功能。
- 应用 eBPF 的 gobinding 对 GPFS 进行 io 侦测以更好报系统瓶颈。

研究经历

加州大学圣克鲁兹分校存储中心 08/2022 – 现在

(研究生科研) 助理

- 设计 CXL.mem 的性能分析、数据驱动的远端内存分配、预取和替换策略的操作系统。🏆
- 设计一种硬件软件协同的 CXL.cache 数据迁移方法。📦
- 设计一种基于 Wasm 和 PTX 的通用迁移方法。^{MV}_{VM}
- 设计一种基于用户态内核态 eBPF 协同工作的分布式系统。🐛
- 参与了 vLLM/SGLang 的开发以实现高吞吐量推理服务, 实现了基于 CXL 的自定义 CUDA attention 内核, 并优化了 KV cache 管理及连续批处理策略以提升整体性能。🔧

主要论文

"SlugArch: A Boundary Replay Contract for Heterogeneous CXL Systems" Preprint Yiwei Yang, Andi Quinn.

"WIO: Upload-Enabled Computational Storage on CXL SSDs" Preprint Yiwei Yang, Yanpeng Hu, Yusheng Zheng, Estabon Ramos, Jianchang Su, Andi Quinn, Wei Zhang.

"CXLMemUring: Revolutionizing Memory Access Through Compiler-Driven Heterogeneous Execution" Preprint Yiwei Yang, Yusheng Zheng, Yuyi Li, Jianchang Su, Wei Zhang, Andi Quinn.

"MVVM: Heterogeneous Checkpoint/Restore with Host-Specialized AOT Execution" Preprint Yiwei Yang, Aibo Hu, Yusheng Zheng, Brian Zhao, Xinqi Zhang, Andi Quinn.

"TernIP: Scaling Ternary Large Language Models" Preprint Ethan Sifferman, Eddy Abban, Yiwei Yang, Dustin Richmond.

"Concordia: JIT-Compiled Persistent-Kernel Checkpointing for Fault-Tolerant LLM Inference" Preprint Yuhang Gan, Yiwei Yang, Yuyi Li, Xiangyu Gao, Yichen Wang, Rain Jiang, Xiaoning Ding, Andi Quinn, Chen Qian.

"Safe and Programmable OS-Level GPU Resource Management with eBPF" ASPLOS27 Yusheng Zheng, Tong Yu, Yiwei Yang, Minghui Jiang, Xiangyu Gao, Jianchang Su, Yanpeng Hu, Wenan Mao, Wei Zhang, Dan Williams, Andi Quinn.

"OCEAN: Open-source CXL Emulation at Hyperscale Architecture and Networking" SC26 Yiwei Yang, Mujahid Al Rafi, Kenza Bouasker, Zhen Peng, Xi Wang, Jesun Sahariar Firoz, Sayan Ghosh, Daniel Wong, Dong Li, Hyeran Jeon, Kevin Barker, Nathan Tallent, Andres Marquez and Luanzheng Guo.

"hetGPU: Pushing pooling into heterogeneous GPU Domain" HCDS26 Yiwei Yang, Yusheng Zheng, Tong Yu, Andi Quinn.

"CXLMemSim: Practical Performance Simulation and Characterization of CXL 3.0 Memory Systems" HPDC26 Yiwei Yang, Pooneh Safayenikoo, Jiacheng Ma, Tanvir Ahmed Khan, Andi Quinn.

"Extending Applications Safely and Efficiently" OSDI25 Yusheng Zheng, Tong Yu, Yiwei Yang, Yanpeng Hu, Xiaozheng Lai, Dan Williams, Andi Quinn.

"Kgent: Kernel Extensions Large Language Model Agent" eBPF24 Yusheng Zheng, Yiwei Yang, Maolin Chen, Andi Quinn.

技能

- 编程语言: 不局限于特定编程语言, 且尤其熟悉 Verilog/C++/Rust 等, 了解 Golang/C/Java/TypeScript 等。
- 系统: 熟悉各种 CPU, 编译器及操作系统内核的概念与设计, 熟悉各种内核性能调优工具, 例如 LLVM, MLIR, Gem5, WASM, gdb, eBPF, ptx, qemu, chisel, Linux mm & observability 子系统。
- 机器学习: 熟悉经典机器学习与强化学习算法, 对 System for LLM for System 有兴趣。

其他

- 兴趣: 高性能计算、体系结构、安全、JIT、CXL、LLM4Sys4LLM 等。
- 带领GeekPie_HPC SCC21 团队第 2 名, ISC22 团队第 4 名, 指导 Not-Slow-Slug 团队 ISC23 团队第 2 名。
- 指导 Kiki Zhang, Zhen Cao 成为博士生。